

Quokka / InvBench 復現

DeepSeek V4 Pro 後端 • 866 benchmarks

復現報告

mazu

2026-06-03

論文 gpt-5.2 列僅參考 • 本機未重跑

Quokka 原流程（未改演算法）



soundness 來自 UAutomizer • 不信 LLM 原文

一次 LLM 呼叫 $\leftrightarrow$ 一個 loop

1. 先掃 while/for/do：每個 loop 一個插入點 $\rightarrow$ {POINTS}
2. **一次 API**：prompt 要求只輸出 **一條** `assume(...)`
3. **哪個 loop**？模型從 {POINTS} **自選** 一行（非每 loop 各 call）
4. Best-of-16：16 次獨立呼叫；每次仍 1 條，**不保證** 覆蓋所有 loop

多 loop 題（如 egcd2）的 #Corr 受「是否抽到關鍵 loop」影響

本次復現改動


項目	設定
後端	DeepSeek V4 Pro
Best-of-N	16 (API 僅 n=1)
排程	one_prime_parallel
Temperature	0.2 主 • 0.7 對照
Reasoning	off

復現目標：跑通 artifact • 非嚴格模型對照 • 未重跑

gpt-5.2

官方結果 (single-pass)

設定	#Corr	#Ext@30s	PAR@30s
論文參考	710	21	22.2s
DS t=0.2	703	48	11.4s
DS t=0.7	691	59	13.1s



主設定 t=0.2 • 不宣稱勝負

Testcase 限制

	Timeout	解出	未解
加速基準	30s	748	118
	500s	863	3

勿混用

- ▶ #Ext@30s 有鑑別力
- ▶ #Ext@500s ≤ 3
- ▶ FALSE 可能是 timeout 標籤
- ▶ semantic_extension $\neq$ #Ext@T
- ▶ 一次 sample 只插一個 loop

#Ext@500s 三題

題目	Baseline	DeepSeek	質性
prodbin-ll	541s	248s ✓	成功
egcd2_2	515s	6s ✓	成功
bresenham	FALSE 508s	assume×	artifact

官方計數 3 題 • 質性成功 2 題 • 非線性算術 + 未

證不變式

結論

- ▶ Quokka + DeepSeek 跑通 866 題；#Corr = 703/866
- ▶ 短時限 **#Ext@30s**、PAR@30s 最有訊息
- ▶ 詳細報告：`deepseek_reproduction_report.md`

`print_results.py` • `analyze_deepseek_results.py`